

주간 학습 보고서

MLLM 기반 TSAD — 실험 비교 + 논문 리뷰

실험 결과 · Anomaly 분류 · TAMA · MADLLM · VLM4TS 다변량

실험 결과

LLM-TSAD vs VLM4TS vs ViT4TS | SMAP + realAWSCloudwatch

Dataset	Metric	LLM-TSAD	VLM4TS	ViT4TS
SMAP	F1	0.2876	0.4614	0.4485
	Affinity F1	0.6346	0.8384	0.7667
realAWSCloudwatch	F1	0.2917	0.3864	0.3678
	Affinity F1	0.7313	0.7739	0.7593

LLM-TSAD의 F1는 낮지만 Affinity-F1은 높음 → anomaly 위치를 대략 잡지만 정확한 구간은 못 잡음


VLM4TS verify step의 실질적 효과 — false positive를 줄이고 precision 향상에 실제 기여

TS Anomaly 유형 분류

유형	정의 / 특징	탐지 어려운 이유
Point	특정 시점 값이 비정상적으로 큼/작음	작은 이상은 정상과 구분 어려움 (작은 spike)
Range	일정 구간 전체가 이상 상태	—
Trend	전체 흐름(기울기)이 변함	계절성
Frequency	주기/진동/국소 패턴이 깨짐	정상적인 주기 정의 자체가 모호, 계절성
Contextual	값은 정상 범위지만 맥락상 이상	LLM이 복잡한 temporal context 이해 못함
Multivariate	단변량으로 보면 정상이지만 변수 간 상관관계가 깨짐	단변량 모델로는 불가능
Irregular	비균일 샘플링 시계열에서 발생하는 이상	균일 샘플링을 가정하는 대부분의 모델에서 전처리 단계부터 문제

TAMA — 구조

See it, Think it, Sorted: Large Multimodal Models are Few-shot Time Series Anomaly Analyzers



문제 방대한 학습 데이터 필요 · 설명 불가능 · LLM의 수치 인식 한계

해결 수치→이미지(See it) + reference learning & self-reflection(Think it) + 자연어 해석(Sorted)

TAMA — 느낀점

1 seasonal/frequency 취약점은 LMM 공통 한계 — 사전학습 데이터에 주파수 자료 부족, 푸리에 변환 전처리 결합 필요

2 self-reflection의 효과가 실질적 — mean 성능을 안정적으로 향상

3 AnomLLM-anomaly 예시 기반 few-shot은 항상 유효하지 않지만, 정상 패턴 기반 reference learning은 효과적

4 univariate 한계 — 실제 산업 현장은 다변량 데이터가 대부분, 변수 간 상관관계를 못 잡음

MADLLM — 구조

Multivariate Anomaly Detection via Pre-trained LLMs




Fig. 2: The architecture of MADLLM.

P1 변수 간 상관관계 무시 — MTS를 univariate로 독립 나열

P2 과거 정보 망각 — 여러 변수를 직렬로 길게 연결 시

S1 Feature Embedding — contrastive learning으로 상관관계 학습

S2 Skip Embedding — 같은 시간대 패치를 변수별로 번갈아 배치, 망각 방지

MADLLM — 느낀점

1 문제를 정확하게 아는 것의 중요성 — LLM이 왜 다변량 시계열에서 실패하는지를 정확히 분석

2 MTS input의 중요성 — 단순 입력 시 피처 간 관계 무시 + 앞 피처 정보 망각 발생

3 다변량 시계열의 본질적 복잡성 — 피처들 사이 관계가 핵심, 하나만 정상이어도 정상일 수 있음

4 LLM 일부 freeze + 피처 임베딩 인코더만 주기적 fine-tuning — 시간↓ + 성능↑ 인상적

TAMA vs MADLLM — 장단점 비교

TAMA

장점

- ▶ 수치→이미지 변환으로 LLM의 숫자 인식 한계 우회
- ▶ self-reflection으로 안정적 성능 향상
- ▶ 탐지 결과를 자연어로 설명 가능

단점 / 한계

- ▶ 프롬프트 3단계 구조 → 추론 비용 높음, 실시간 적용 어려움
- ▶ 정상 레퍼런스 품질에 성능이 크게 의존
- ▶ 단변량만 처리 — 변수 간 상관관계 미반영

MADLLM

장점

- ▶ Triple Encoding으로 다변량 상관관계 + 시간 패턴 동시 포착
- ▶ LLM freeze + 임베딩 인코더만 fine-tuning → 학습 시간↓, 성능↑

단점 / 한계

- ▶ 채널 직렬 나열 구조 → 변수 많을수록 시퀀스 길이 급증
- ▶ 이진 출력(0/1) — 이상 심각도·유형 구분 불가
- ▶ SMD 데이터셋에서 성능 낮음 — 차이 증폭 부족

VLM4TS — 다변량 확장

MADLLM과의 비교 관점

MADLLM과의 차이

VLM4TS: GPT-4o가 전체 채널 시각화를 보고 cross-channel 맥락으로 판단

MADLLM: contrastive learning으로 feature 간 상관관계를 학습해서, 정교한 수치적 상관관계를 직접 모델링

접근 방식

- ▶ 1단계: ViT4TS를 각 채널에 독립적으로 적용 -> 채널 별 candidate anomaly 구간 생성 후 모든 채널의 candidate구간 통합 텍스트 요약
- ▶ 2단계: 전체 다변량 시계열의 stacked-subplot 이미지 생성 (채널 전체를 한번에 시각화)
- ▶ 3단계 : VLM4TS가 두 입력을 함께 보고 cross-channel 추론하여 최종 다변량 이상 구간 추정

장점	단점 / 한계
구조 변경 없이 자연스러운 확장 — 단변량·다변량 모두 사용 가능	채널 수 증가 시 토큰 폭발
이미지로 한번에 맥락 파악	이미지 해상도 문제 — stacked 시 세로 픽셀 감소
2차 이상탐지를 통한 false positive 감소	채널 간 역상관 이상 패턴 놓칠 수 있음
Fine tuning이 필요하지 않음	1단계에서 각 채널 독립 처리 / 채널 수 증가 시 집중할 채널 놓칠 수 있음

01

다변량 확장

현재 단변량 중심 분석을 다변량 상관관계까지 확장

02

추가 논문 읽기

다변량 TSAD 관련 최신 논문 탐색