

주간 학습 보고서

ViT Backbone 비교 실험 — MAE Scoring 고도화 + DINOv2 스케일 실험

실험 결과 · VAN-AD 논문 · MAE 실험 · DINO 실험

CLIP / DINOv2 / MAE — Backbone 구조 비교

구분	CLIP	DINOv2	MAE
학습 방식	Contrastive Learning (이미지-텍스트 쌍)	Student-Teacher Distillation (iBOT+DINO)	Masked Patch Reconstruction
강점	전역 패턴 비교 주기적 신호에 유리	Patch feature 품질 우수 Non-stationary에 안정적	Local texture 이상 특화 Semantic bias 없음
약점	Non-stationary 신호에 급격한 성능 저하	MSL 등 복잡 구조에서 semantic feature 방해	Over-generalization Local perception 한계

저번주 실험 — Stage 1 Backbone 비교 결과

MSL

이상 유형 다양

이상 구간 길이, 형태(spike-drift-distortion 등)가 다양해 잡기 어려움

SMAP

비교적 쉬움

정상 분포가 안정적이라 정상/이상 경계가 상대적으로 명확한 편

NAB-AWS

Non-stationary

정상 기준 자체가 시간에 따라 바뀜 → non-stationary

주요 결과

데이터셋	논문 (VIT4TS)	1위	F1 ↑	2위	3위
MSL	0.543	MAE	0.621	Clip = 0.543	DINO = 0.4216
SMAP	0.726	CLIP	0.753	DINO = 0.7105	MAE = 0.5833
NAB-AWS	0.400	DINOV2	0.525	Clip = 0.420	MAE = 0.3529

단일 backbone이 전 데이터셋에서 우위를 점하지 못함. 데이터의 stationarity와 이상 유형에 따라 최적 backbone이 달라짐.

저번주 실험 — 후속실험 LTR 도입.

후속 실험 — MAE , NAB-AWS 데이터에 대해 Local Temporal Reference (LTR)

NAB-AWS, MAE backbone · global ref → 시간적 인접 k개 윈도우 참조

참조 범위 k	F1	global 대비
k = 5	0.627	+69.8%
k = 10	0.561	+51.6%
k = 20	0.396	+7.0%
global	0.370	baseline

k가 작을수록 성능 향상.
NAB-AWS처럼 분포 변화가 잦은 데이터에서
현재 시점 인근만 참조하는 것이 효과적.

Backbone별 LTR(k=5) 효과

NAB-AWS 데이터셋 기준

Backbone	Global	k = 5	변화
MAE	0.353	0.627	+0.274 ↑↑
CLIP	0.364	0.558	+0.195 ↑
DINO	0.512	0.499	-0.013 ↓

MAE·CLIP은 LTR로 큰 폭 향상.
DINO는 global reference가 이미 충분해
국소 참조의 이점이 없음.

이번주 실험 — DINOv2 Scoring 전략 비교- CLS 토큰 사용

방법	SMAP	MSL	NAB-AWS
DINO_CLS-G	0.955	0.339	0.521
DINO_CLS_Fusion_KNN	0.804	0.598	0.417
논문 (vit4ts)	0.726	0.543	0.400

DINO_CLS-G

윈도우 전체를 CLS 1벡터로 압축
+ contextual anomaly 탐지 강화 (SMAP 0.955)


- spike·단기 trend가 압축 과정에서 희석 → MSL
0.339 저조

DINO_CLS_fusion_KNN


4가지 윈도우 크기(56/112/224/336)에서 KNN 합산
+CLS 보다 trend,frequency anomaly 탐지 강화

- 스케일 평균 합산 과정에서 subtle contextual 신호
희석

P-1 (P-1 채널 patch 방식 0.33-> CLS 방식 둘다 1.00)



T-13 (T-13 채널 CLS-G 방식 0.00-> CLS-fusion 방식 0.677)



이번주 실험 — DINOv2 Scoring 전략 비교-patch방식


방법	SMAP	MSL	NAB-AWS
DINO_PG KNN	0.859	0.695	0.463
논문 (vit4ts)	0.726	0.543	0.400

DINO_PatchGrouped KNN


패치를 시간 축 방향으로 그룹화
+trend·range 탐지 최강 (MSL 0.695)

-patch 방식이다보니 contextual 탐지력이 낮아짐.

T-1 채널 - vit 방식 (0.00)-> PatchGroup (1.00)



P-1 채널 탐지 실패 (0.33)



VAN-AD — 논문 리뷰

Visual Masked Autoencoder with Normalizing Flow For Time Series Anomaly Detection (2026년 3월)


MAE를 TSAD에 직접 적용 시 두 가지 문제

Over-generalization


MAE의 복원 능력이 너무 강해 이상 구간도 정상처럼 재구성 → 재구성 오차가 낮게 측정됨

Local Perception 한계

슬라이딩 윈도우 전체가 이상 상태일 경우, 내부 변화 부재로 정상으로 오인 (Drift, Level Shift 등)




(a) Over Generalization



(b) Local Perception

느낀점 : reconstruction error 사용의 필요성

전체 파이프라인



Forward Module	다변량 시계열 → 224×224 heatmap
Checkerboard Mask	보완 mask 2개 → 완전 커버리지
ADMM	over generalization 해결 재구성 결과를 mean/std 정렬 → 이상 오차 증폭해서 오차를 더 잘보이게함
NFM	local perception 해결 정상 분포 모델링 → 밀도 기반 이상 점수

VAN-AD는 2025년 최첨단 모델인 CATCH 대비 평균 성능을 최대 36.4% 향상시키며, 9개 데이터셋에서 일관되게 새로운 SOTA를 기록

이번주 실험 — MAE Scoring 전략 고도화 (1/2)

STEP 1

GAP(global average pooling) 도입 — Trend / Range anomaly 해결

LTR에 전체 평균(GAP)을 혼합($\alpha=0.7$) (gap을 전체시퀀스의 median과 비교.
현재 윈도우가 전체흐름에서 얼마나 벗어났는지 측정)
→ drift-level shift 탐지 보완

Dataset	LTR k=5	GAP $\alpha=0.7$
SMAP	0.5726	0.7194 ↑
NAB	0.6272	0.6983 ↑
MSL	0.6344	0.6864 ↑

세 데이터셋 모두 향상.
단, non-stationary가 심한 데이터에서는
GAP 의존도 증가 시 성능 저하.

STEP 2

RMS(root mean square) 도입 — Amplitude 변화 탐지

평균만 보는 GAP의 한계 →
신호 에너지(RMS) 변화 측정 (GRMS $\alpha=0.5$)

조건	SMAP avg	T-1 채널
DA $\alpha=0.7$	0.7194	0.0000
GRMS $\alpha=0.5$	0.7762 ↑	0.4000 ↑

T-1 (amplitude decrease) 첫 감지 성공.
단, 다른 데이터셋에서는 성능 후퇴.
→ RMS는 특정 이상 유형에만 선택적으로 유효.

이번주 실험 — MAE Scoring 전략 고도화 (2/2)

STEP 3

Reconstruction Error 결합

Over-generalization 해결 시도

VAN-AD 아이디어 참고 →
pixel-space 재구성 오차를 선형 결합 ($\beta=0.9$)

Dataset	LTR k=5	recon err
SMAP	0.5726	0.7952 ↑
MSL	0.6344	0.5974 ↓
NAB	0.6272	0.5922 ↓

결과 해석

- 1 SMAP만 개선된 이유 — SMAP은 복원 불가 구간이 뚜렷해 recon error가 이상 신호로 작용
- 2 MSL·NAB 성능 후퇴 — 정상 구간에서도 recon error가 크게 발생 → false positive 증가
- 3 단순 선형 결합의 한계 — VAN-AD의 ADMM처럼 정상 분포 기준으로 오차를 정규화하지 않으면 노이즈로 작용

느낀점

reconstruction error를 활용하려면 raw 값 그대로가 아니라 ADMM/NFM처럼 정상 분포 기준으로 정규화하는 구조가 필요.

다음 계획

01

Backbone 결정

MAE / DINOv2 실험 결과를 종합하여 최종 backbone 선택 및 방향 확정

02

Reconstruction Error 체계화

VAN-AD의 ADMM/NFM 방식 참고 → 우리 구조에 맞는 discrepancy 적용 방법 탐색

03

Spike 희석 문제 해결

DINO 방법들의 공통 한계 해소 → patch 단위 max pooling 등 대안 실험