

20주차 실험 정리 — top-8 채널 선택 개선 (SMD, 48개 실제 GT 세그먼트)

1. top-8 고정 선정이 괜찮은가? — GT 채널 수(k) 분포

k 구간	1-3개	4-8개	9-15개	16-38개
세그먼트 비율	35.4%	33.3%	22.9%	8.3% (최대 34/38)

→ 결론: k가 1~34로 매우 넓게 퍼져있어 “항상 8개”라는 가정 자체가 구조적으로 안 맞음. k=16-38 구간은 top-8로 이론상 최대 24%밖에 못 잡음 (8/34).

2. 대안 설계: residual sum 기반 3단계 selective verification

38채널 각각 z-score(자기 참조, DINOv2 patch-KNN residual sum) 계산 → ① z 매우 큼 → VLM 없이 자동 “이상” 확정 / ② z 애매함 → lineplot으로 VLM에게 판단시킴 / ③ z 매우 작음 → 자동 “정상” 확정. top-8처럼 개수를 고정하지 않고 애매한 것만 가변 개수로 VLM에 보여주므로, “lineplot에 8개만 넣을 수 있다”는 제약도 자연히 완화됨.

3. residual sum 적응형 선택 실제 결과 ($\alpha = 0.01$) vs top-8(5-ref production)

k 구간	top-8: P / R	적응형: P / R
1-3	0.191 / 0.706	0.182 / 0.618
4-8	0.477 / 0.631	0.432 / 0.629
9-15	0.511 / 0.326	0.580 / 0.539
16-38	1.000 / 0.293	0.942 / 0.721

→ k=16-38 구간 recall 0.29→0.72로 급등 (k=34 세그먼트 2개는 P=R=1.0). 단, k=1-3은 top-8이 근소하게 더 나옴 — α 는 0.01 정도가 precision/recall 균형점.

4. 3단계(확실히 이상 / 애매함 / 확실히 정상) 실제 분할 결과

GT 채널 395개가 어느 그룹에 있었나:

그룹	뜻	GT 채널 수
확실히 이상	VLM 없이 바로 “이상”으로 확정	249개 (63%)
애매함	VLM한테 보여줘서 판단 맡김	52개 (13%)
확실히 정상	VLM한테 보여주지도 않고 바로 버림	94개 (24%)

성능:

	맞춘 비율(정밀도)	놓치지 않은 비율(재현율)
VLM 없이, “확실히 이상”만으로 판단	42%	61%
VLM이 “애매함”도 다 완벽히 맞췄다고 치면(최선)	49%	78%

→ “확실히 정상”이라고 버린 94개(전체 정답의 24%)는 VLM한테 보여주지도 않으니, VLM이 제아무리 잘해도 절대 못 잡음 — 지금 가장 큰 구멍. line plot으로 직접 확인한 원인은 3가지: ①너무 짧은 스파이크(256패치 sum에 희석) · ②224픽보다 긴 이상구간(창 안에 정상 비교기준 없음, 완만한 추세로만 보임) · ③정상일 때도 비슷하게 튀는 채널(크기만으론 이상 시점 구별 불가, 근본적으로 더 어려운 문제).