

Stage2 사전 진단: Oracle-Clean & DINO Relation Mini Sanity Check

목적: Stage1(DINOv2 이미지 인코딩) + Stage2(LLM) 2단계 다변량 시계열 이상탐지 파이프라인에서, Stage2가 다변량 채널 간 root cause/propagation을 얼마나 잘 추론하는지 사전 검증.

실험 1 (Oracle-Clean): Stage1 이미지를 거치지 않고 GT를 텍스트로 직접 LLM에 제공했을 때 root cause 추론 성능이 기존 overlay 이미지 방식보다 높은지 확인 -> LLM 추론력의 상한선을 측정.


실험 2 (DINO Relation Mini Sanity Check): DINO embedding 간 거리가 채널 간 '관계 강도'를 반영하는 신호로 쓸 수 있는지, LLM 호출 없이 로컬 계산만으로 사전 검증.

실험 1 결과 — Overlay / Subplot / Oracle-Clean 비교

Metric	Overlay	Subplot	Oracle-Clean
Root cause accuracy	55.5%	26.2%	99.7%
Onset MAE (step)	53.8	67.5	0.1
Affected-set F1	61.3%	44.6%	97.8%
NORMAL FP rate	0.0%	23.3%	0.0%
n (sample)	382	389	390

Oracle-Clean: 이미지 없이 GT(onset/breakdown_type/intensity)를 텍스트로만 제공. n=390(NORMAL 제외 360 + NORMAL 30), Overlay/Subplot과 동일한 390개 원본 샘플

n_affected별 root cause accuracy — Overlay vs Oracle-Clean





실험 1 — Oracle-Clean 실패 사례 (confidently wrong)

전체 360건 중 root cause 오답은 1건.

(NA2_LAG50_012) true_root=5 pred_root=1 confidence=0.85
reason: Channel 1 and Channel 6 have the same breakdown type C4 starting at the same time, but Channel 1 has higher intensity, suggesting it as the root cause. Channel 5 has a different breakdown type and earlier onset, indicating it is unrelated.

실험 2 — DINO embedding delta 분포 (root vs 나머지 5채널, cascade/mild/unrelated)



실험 2 — Kruskal-Wallis 검정 결과 (1차)

Comparison	H	p-value	Group means
CLS / role (casc-mild-unrel)	15.075	0.0005326	cascade=0.0399, mild=0.0368, unrelated=0.0358
Patch / role (casc-mild-unrel)	23.983	6.196e-06	cascade=0.0465, mild=0.0398, unrelated=0.0394
CLS / homog. vs heterog.	32.666	1.094e-08	False=0.0521, True=0.0251
Patch / homog. vs heterog.	36.696	1.381e-09	False=0.0533, True=0.0331


주의: n=1800으로 커서 p-value가 작아도 효과크기가 노이즈 수준일 수 있음 -> 다음 페이지에서 effect size로 재검증.

실험 2 (추가) — 표현/비교축별 Effect Size 비교


Representation	role d	role AUC	role p	type-match d	type-match AUC	type-match p
CLS (final layer)	0.051	0.521	0.22	-0.362	0.390	1.1e-08
Patch-mean (final layer)	0.096	0.534	0.042	-0.291	0.383	1.4e-09
Mid-layer CLS (block 5)	-0.144	0.483	0.32	-0.360	0.348	2.6e-15
Last-layer attention map	0.035	0.475	0.15	-1.188	0.179	1.6e-62

role = cascade vs unrelated. type-match = homogeneous vs heterogeneous (affected 채널만, breakdown_type 일치 여부).
|d| < 0.2 negligible, 0.2~0.5 small, 0.5~0.8 medium, > 0.8 large (Cohen 기준). AUC 0.5=구분력 없음.
실패 패턴 비율(샘플 단위, affected 평균 delta < unrelated 평균 delta): CLS 42.5%, patch-mean 37.9% (n=240).


Last-layer attention map — delta by breakdown_type match ($d=-1.19$, $AUC=0.18$, $p=1.6e-62$)



잘 분리된 대표 샘플: NA4_LAG50_001 (separation score=+0.0929)



안 분리된 대표 샘플: NA1_LAG50_003 (separation score=-0.1170)



종합 판단

Oracle-Clean root accuracy = 99.7% vs Overlay = 55.5%

-> Oracle이 Overlay보다 유의미하게 높다면, 현재 파이프라인의 병목은 Stage1 시각 인코딩이지 LLM의 인과 추론 능력 자체가 아니라는 뜻 -> Stage1 이미지 표현을 개선하는 방향이 유효함.

[재검증] p-value 대신 effect size로 보면: role(cascade vs unrelated) $d=0.05$, $AUC=0.52$ -> 사실상 노이즈 수준 ($|d| < 0.2$, $AUC \sim 0.5$).
breakdown_type 일치 여부(homogeneous vs heterogeneous, affected만) $d=-0.36$, $AUC=0.39$ -> role보다 3~7배 크지만 여전히 small~medium. 샘플 단위 실패율(unrelated가 affected보다 delta 큼) 42%.

[레이어 비교] mid-layer CLS는 final CLS와 비슷한 수준(role/type-match 모두 개선 없음).
반면 last-layer attention map은 role 신호는 여전히 0에 가깝지만($d=0.04$),
breakdown_type 일치 여부에서는 $d=-1.19$, $AUC=0.18$ 로 large effect (Cohen 기준 $|d| > 0.8$).

-> 결론 수정: DINO 거리를 'root와의 relation 강도'(role) 신호로 쓰는 것은 근거가 약함(노이즈 수준, 샘플 단위 실패율 40% 안팎). 그러나 last-layer attention map은 '두 채널이 같은 종류의 이상 패턴을 보이는가'(breakdown_type match)를 매우 강하게 포착함 -> RQ1에서는 DINO 거리를 root-cause 판별용이 아니라, 채널을 '같은 이상 시그니처끼리' 클러스터링하는 용도로 재정의해서 시도해볼 가치가 있음. 다만 이는 학습 시점에만 알 수 있는 GT(homogeneous)로 검증한 것이라, 실제 추론 시점에 쓸 수 있는 형태(비지도 클러스터링 등)로 재설계가 필요함.