

자세한 실험결과 Sanity9

인과적 근본원인 / 전파 구조 (Causal Root-Cause & Propagation)

▼ 실험 시나리오(경우의수) 및 결과 요약

▼ 13개 시나리오란 무엇인가

두 축의 조합입니다 — **NA(n_affected)** = root 말고 몇 개 채널이 실제로 영향을 받았는지(0~5), **LAG** = 그 채널들이 root보다 몇 스텝 늦게 반응하기 시작했는지(10 또는 50 step). **NORMAL**은 이 두 축과 무관하게 이상 자체가 없는 완전 정상 6채널(오탐률 측정용 음성 대조군)이다. 시나리오 안에서 반응 채널이 root와 같은 붕괴유형인지(homogeneous) 다른 유형인지(heterogeneous), 강하게(cascade) 반응하는지 약하게(mild) 반응하는지는 매번 랜덤으로 섞여서 30회 반복 안에 자연스럽게 커버된다.

시나리오	의미
NA0_LAG10 / NA0_LAG50	root 1개만 이상 발생, 영향받는 채널 0개 (아무도 안 따라옴). lag는 반응 채널이 없어 사실상 무의미
NA1_LAG10 / NA1_LAG50	root 1개 + 1개 채널 이 root_onset+10(또는 +50) 시점부터 반응
NA2_LAG10 / NA2_LAG50	root 1개 + 2개 채널 이 반응
NA3_LAG10 / NA3_LAG50	root 1개 + 3개 채널 이 반응
NA4_LAG10 / NA4_LAG50	root 1개 + 4개 채널 이 반응
NA5_LAG10 / NA5_LAG50	root 1개 + 나머지 5개 채널 전부 가 반응
NORMAL	root 자체가 없음 — 6채널 전부 정상 (음성 대조군)

▼ 전체 경우의수(13 시나리오 × 2 시각화 = 26) 결과

시나리오당 약 30회 반복, 실제 GPT-4o(temperature=0) 호출.

시나리오	n_affected	lag	시각화	n	Root 정확도	Onset MAE
NA0_LAG10	0	10	overlay	30	93.3%	96.7
NA0_LAG10	0	10	subplot	30	53.3%	88.9
NA0_LAG50	0	50	overlay	27	92.6%	81.5
NA0_LAG50	0	50	subplot	30	36.7%	93.3
NA1_LAG10	1	10	overlay	30	50.0%	46.3
NA1_LAG10	1	10	subplot	30	33.3%	81.6
NA1_LAG50	1	50	overlay	30	83.3%	55.2
NA1_LAG50	1	50	subplot	30	26.7%	92.9
NA2_LAG10	2	10	overlay	30	33.3%	48.1
NA2_LAG10	2	10	subplot	30	16.7%	60.5
NA2_LAG50	2	50	overlay	27	59.3%	52.0

NA2_LAG50	2	50	subplot	30	13.3%	65.6
NA3_LAG10	3	10	overlay	29	17.2%	24.1
NA3_LAG10	3	10	subplot	30	20.0%	56.0
NA3_LAG50	3	50	overlay	29	62.1%	65.5
NA3_LAG50	3	50	subplot	30	16.7%	73.7
NA4_LAG10	4	10	overlay	30	23.3%	45.0
NA4_LAG10	4	10	subplot	29	3.4% ⚠	42.0
NA4_LAG50	4	50	overlay	30	53.3%	53.3
NA4_LAG50	4	50	subplot	30	13.3%	79.2
NA5_LAG10	5	10	overlay	30	23.3%	20.7
NA5_LAG10	5	10	subplot	30	10.0%	36.0
NA5_LAG50	5	50	overlay	30	33.3%	56.7
NA5_LAG50	5	50	subplot	30	20.0%	70.4
NORMAL	-	-	overlay	30	100%	-
NORMAL	-	-	subplot	30	76.7%	-

⇒ 26개 경우의수 중 overlay가 subplot을 이긴 경우가 24/26 (NA3_LAG10만 유일하게 subplot이 근소하게 앞섬 — 표본이 작아 노이즈일 가능성이 높음). NA4_LAG10의 subplot은 3.4%로 전체 최저치.

▼ 목적

Sanity-6(multi-channel 실험)에서 두 가지 미해결 문제가 드러났다:

- **오귀속(Misattribution)** — 이상은 감지하지만 엉뚱한 채널쌍을 지목 (놓친 사례의 약 15%)
- **순서 효과(Order Effect)** — 여러 쌍을 한 번에 판단시키면 뒤쪽 쌍의 정확도가 42~46%까지 하락

이 두 문제는 다변량 이상탐지 도메인에서 더 근본적인 문제의 표층일 가능성이 있다:

- 원인-결과 방향 혼동 (Root Cause vs Symptom)
- 전파 지연(Propagation Lag) 추정 실패 — 시차를 놓치면 "무관하다"고 오판
- 이질적 전파(Heterogeneous propagation) — 원인의 붕괴 유형과 여파의 붕괴 유형이 다를 수 있음
- 약한 신호가 다수결에 묻힘

Sanity-9는 이 네 가지를 직접 겨냥한다. 사전 정의된 그룹/페어링 없이, 매 샘플마다 **랜덤한 인과 구조**를 생성하고 모델이 이를 스스로 추론하게 한다. 추가로, **같은 데이터를 overlay(겹침) vs subplot(분리)** 두 가지 시각화로 각각 렌더링해서 표현 방식 자체가 인과 추론 성능에 미치는 영향도 함께 검증한다.

▼ 방법

▼ 데이터 생성 구조

6채널 고정(채널1~6). 매 샘플마다 역할이 랜덤 재배정된다 (고정된 그룹 개념 없음).

역할	정의
root	최초로 이상이 발생한 원인 채널. C1~C5(진폭점프/flatline/위상반전/점진적 드리프트/미세 주파수변화) 중 랜덤 1종, t=100에서 abrupt 발생
cascade	root_onset + lag 이후 강하고 즉각적으로 동반 붕괴(intensity=1.0)
mild	root_onset + lag 이후 약하고 점진적으로 동반 붕괴(intensity=0.35, 완만한 ramp-in)
unrelated	root와 무관, 정상 패턴 유지(자체 노이즈만)

cascade/mild 채널은 각각 root와 같은 붕괴유형(homogeneous) 또는 다른 유형(heterogeneous)으로 반응하도록 50/50 랜덤 배정된다. 전부 정상인 **NORMAL** 샘플(root 없음)도 별도 시나리오로 포함.

▼ 실험 조건 (파일럿 축)

축	옵션
영향받는 채널 수 (n_affected)	0, 1, 2, 3, 4, 5
lag 크기	짧음(10 step) / 김(50 step)
시각화	Overlay(겹침) / Subplot(6단 분리, x축만 공유)

$6 \times 2 = 12$ 시나리오 + NORMAL(음성 대조군) 1개 = **13 시나리오** × 30회 반복 × 2 시각화 조건 = 총 **780건** 실제 GPT-4o(temperature=0) 호출.

▼ 모델 과제 및 프롬프트

You are shown a plot of 6 time-series channels, labeled "1" through "6", plotted over the same time axis from time step 0 to 299. The channels may influence each other, or some may be completely unrelated to the others -- there is no predetermined grouping; you must infer any structure yourself from the plot.

Task:

1. If there is a channel where an anomaly first originated (a "root cause" channel), identify which one it is. If all 6 channels look normal throughout, answer "none".
2. Identify all channels that became anomalous as a consequence of the root cause, including channels that only react after a delay or react only weakly/gradually.

3. Identify all channels that stay in their normal pattern, unrelated to the root cause.
4. Estimate the time step at which the root cause channel's anomaly first began (null if there is no root cause).

Respond with only the following JSON object, no markdown and no extra text:

```
{"root_cause_channel": "1"- "6" | "none", "affected_channels": [...],  
"unaffected_channels": [...], "onset_time": <integer or null>, "reason": "...",  
"confidence": <0.00-1.00>}
```

▼ 평가 지표

지표	설명
Root cause accuracy	원인 채널 top-1 정답률 (없음="none" 포함)
Affected-set Precision/Recall/F1	root를 제외한 5개 채널에 대한 "영향받음" 판정의 집합 단위 정밀도/재현율
Onset MAE	실제 onset(항상 t=100)과 예측 onset의 step 차이

▼ 결과

▼ 전체 요약

지표	값
n (샘플)	771 / 780 (parse error 9건, 1.2%)
Root cause accuracy	0.407
Onset MAE	59.5 step
Affected-set Precision / Recall / F1	0.620 / 0.465 / 0.531

▼ 핵심 발견 — 시각화 방식이 결과를 지배한다

지표	Overlay	Subplot
Root cause accuracy	0.555	0.262
Onset MAE	53.8 step	67.5 step
Affected-set F1	0.613	0.446
NORMAL 오탐률	0%	23.3%





그림 1. Overlay vs Subplot 핵심 지표 비교 (n=771)


⇒ 모든 n_affected 조건(0~5)에서 예외 없이 overlay가 subplot을 2배 이상 앞섰다.

▼ 같은 샘플, 두 가지 시각화 — 왜 이렇게 차이가 나는가

root=채널6(미세 주파수변화), 영향받는 채널 0개(NA0_LAG10_001)인 동일한 샘플을 두 방식으로 렌더링:



Overlay — 정답(root=6). Ch6(갈색)이 다른 5개와 주기가 어긋나는 게 한눈에 보임.



Subplot — 오답. 각 채널이 독립된 y축(자동 스케일)에 그려져, 서로 다른 패널에 놓인 채널 간의 "동시성 어긋남"이 거의 안 보임.

기술적 원인: subplot 렌더링 함수는 `sharex=True` 만 설정하고 `sharey=True` 는 설정하지 않았다 — 6개 서브플롯이 각자 y축을 독립적으로 자동 스케일링한다. 그 결과 어떤 채널의 미세한 자체 노이즈도 좁은 y축 범위 안에서는 크게 흔들리는 것처럼 보이고, 반대로 채널 간 절대적인 벌어짐 정도를 비교할 기준이 사라진다.

Subplot 오답의 두 가지 패턴 (reason 텍스트)

- 아예 못 봄: *"All channels exhibit similar sinusoidal patterns with no clear anomalies or deviations from their expected behavior."*
- 노이즈를 이상으로 착각: *"Channel 2 shows increased noise throughout the time series, suggesting it is the root cause."*

NORMAL 시나리오에서도 subplot은 없는 이상을 지어낸다




그림 2. NORMAL_005 (subplot) — 실제로는 6채널 전부 정상. 모델은 "Channel 4 shows a deviation from its normal pattern starting around time step 150, which is followed by similar deviations in all other channels"라며 존재하지 않는 root(채널4)와 연쇄반응 서사를 지어냈다.

▼ 채널 수(n_{affected})에 따른 성능 곡선

영향받는 채널 수	Root accuracy (평균)	Onset MAE (평균)
0	68.2%	89.7
1	48.3%	64.2
2	30.0%	55.3
3	28.8%	53.8
4	23.4%	54.2
5	21.7%	45.5




그림 3. n_{affected} 에 따른 root cause accuracy — overlay/subplot 모두 하락하지만 격차는 전 구간 유지

⇒ 영향받는 채널이 많을수록 "언제 시작됐는가"(onset)는 더 잘 맞지만, "누가 원인인가"(root)는 점점 더 못 맞힌다 — 원인 후보가 늘어날수록 오귀속 위험이 커진다는 Sanity-6의 관찰과 같은 메커니즘.

▼ Homogeneous vs Heterogeneous 전파

	Recall (영향 채널 탐지율)
Homogeneous (root와 같은 붕괴유형)	46.1%

Heterogeneous (root와 다른 붕괴유형)	46.9%
-------------------------------	-------

거의 차이 없음 — "원인과 겉모습이 다른 여파"라고 해서 특별히 더 못 찾는 건 아니었다.

▼ Lag(전파 지연)

Lag	Affected F1
10 step	0.530
50 step	0.541

짧은 지연과 긴 지연 사이에 유의미한 차이 없음 — 이번 파일럿 규모(10 vs 50)로는 효과가 뚜렷하지 않았다.

▼ n_affected=0에서 드러난 별도 문제

영향받는 채널이 실제로 0개(root 혼자만 이상)인 시나리오에서도, 채널 단위로 집계하면 **585번의 non-root-channel 평가 중 101번(17.3%)**이 "이 채널도 영향받았다"며 없는 연쇄반응을 만들어냈다.

▼ 종합 결론 및 시사점

1. 가장 강력한 결론: 이 태스크에서는 overlay가 subplot보다 압도적으로 우수하다. 모든 n_{affected} 조건에서 예외 없이 2배 이상 격차가 났고, 특히 오탐률(NORMAL 시나리오)에서 0% vs 23.3%로 극명하게 갈렸다. 여러 채널 사이의 인과관계·시차를 판단해야 하는 태스크에서는 반드시 공유 축(shared axis) 오버레이를 써야 하며, subplot처럼 채널별로 축을 분리하면(특히 y축 독립 스케일링) 심각한 성능 저하와 오탐 증가를 유발한다.
2. Sanity-6의 오귀속·순서효과 문제는 인과추론 자체가 어렵다는 더 큰 문제의 일부였다. 채널 수가 늘수록 "여파 채널 찾기"가 아니라 "진짜 원인 하나를 정확히 짚기"가 훨씬 빠르게 무너진다(68%→22%).
3. 동질/이질 전파, 짧은/긴 지연은 이번 파일럿 규모에서는 뚜렷한 차이를 만들지 않았다 — 표본을 늘리거나 조건을 더 극단화해서 재검증이 필요하다.
4. 다채널 상황에서 "없는 연쇄반응을 지어내는" 경향이 일정 비율(약 17%) 존재한다 — Stage2 검증 파이프라인에 다 채널 causal 판단을 넣는다면 이 기저 오탐률을 감안해야 한다.

▼ 다음 단계 제안

- `sharey=True`를 적용한 subplot 재실행: y축을 공유시키면 overlay와의 격차가 줄어드는지 확인
- Lag를 더 극단적으로(예: 100 step) 확장 테스트
- 동질/이질 전파의 표본 확대로 재현성 확인
- 오귀속 채널이 root와 "인접"한 채널 번호로 쏠리는지 재분석

자세한 실험결과 Sanity9 — Sanity-9 run: 20260716_112728 (실제 GPT-4o, 780건)