

자세한 실험결과Sanity4~7

▼ 실험


▼ Sanity4- stage1후보구간 실험

목적)

- Stage 1이 제안한 후보 구간(red box)이 실제 이상 구간인지 GPT가 검증할 수 있는지 평가
- 출력: valid / invalid

원본 신호 패턴: C0 ~ C6 (총 7종)/각 패턴별 30회 반복/총 210개 샘플 (7 × 30)


V0 - 정상(완전 동기화)



설계)실제 이상 없음/후보 구간([100,200])을 일부러 제시/정답: invalid

결과) 30 / 30


V1,V7-진폭 2배로 튼



V1 (정답 위치)

설계)실제 이상 = 후보 구간
([100,200])/정답: valid

결과)30 / 30



V7 (틀린 위치)

설계)실제 이상과 다른 위치를 후보로
제시/정답: invalid


결과)29 / 30

해석

- 대부분 후보 위치를 정확히 검증.

- 유일한 오답은 실제 이상을 보고 후보도 valid라고 판단.


V2,V8-Flatten



V2 (정답 위치)

설계)실제 flatline = 후보 구간/정답:
valid

결과)30 / 30



V8 (틀린 위치)


설계)실제 flatline은 [100,200]/후보
는 정상 구간([0,100])/정답: invalid

결과)5 / 30

해석


- Sanity-4 최저 성능.
- GPT가 후보 박스 밖의 flatline을 후보 안의 이상으로 착각.
- Flatline처럼 시각적으로 매우 눈에 띄는 이상(saliency)에 특히 취약.

V3,V9-위상 반전



V9 (정답 위치)

설계)실제 이상 = 후보 구간/정답:
valid



V3 (틀린 위치)

설계)실제 이상은 [100,200]/후보는
정상 구간([0,100])/정답: invalid


결과)29 / 30

결과)30 / 30

해석

- 오답 1건은 실제 이상 구간을 보고 후보도 valid라고 판단.
- 대부분은 후보 위치를 정확히 구분.


V4,V10- 위상이 서서히 어긋남



V4 (정답 위치)

설계)실제 이상은 [100,300]/후보는 내부 구간([150,250])/정답: valid

결과)30 / 30



V10 (틀린 위치)


설계)정상 구간을 후보로 제시/정답: invalid

결과)30 / 30

⇒시사점.


- Sanity-3에서는 경계 추정에 실패했던 유형.
- 후보만 정확히 주어지면 완벽하게 검증 가능.-즉, "탐지는 가능하지만 경계 추정만 어려웠던 유형"임을 확인.

V5,V11-미세한 주파수 변화



V5 (정답 위치)

설계)실제 이상 = 후보 구간/정답: valid



설계: 정답 invalid

결과-30/30(잘 알려주는경우)

결과)21 / 30

Precision / Recall / F1 (valid)	1.000 / 0.700 / 0.824
------------------------------------	---------------------------------

⇒V9 덕분에 "후보 위치만 정확하면
어떤 케이스든 거의 완벽하다"는 결론
이 더 강해졌다


해석

- 9건 모두 invalid로 오답.
- 대부분 "두 채널이 계속 함께 움직인다"고 판단.
- 위치를 알려줘도 미세한 주파수 변화 자체를 잘 인식하지 못함.

시사점

- Sanity-1(3.3%) → Sanity-3(10%) → Sanity-4(70%)로 크게 향상,하지만 여전히 가장 어려운 이상 유형.

V6-노이즈



설계)실제 이상 없음/Channel B 노이즈만 증가/후보 구간([100,200])/정답:
invalid

결과)28 / 30

해석

- 노이즈를 이상으로 착각한 오탐 2건 발생.
- 후보가 존재한다는 사실만으로 확인 편향(confirmation bias)이 생길 수 있음을 확인.

▼ Sanity5-구간을 후보로 주는 실험

목적: Sanity-3은 모델이 `break_start` / `break_end` 숫자를 자유생성(free-form)하게 했는데, "숫자를 직접 만들게 하면 오차가 크다"는 가설 하에 — 미리 계산된 후보 지점 중에서 고르게 하면 더 정확해지는지 테스트한 실험


후보 지점 생성)Channel A-B 사이의 rolling cross-correlation(window=24)을 계산해 "관계 점수 곡선"을 만들고, 여기서 4+4개 후보를 뽑음.

후보	계산 방식
L0 / R0	실제 정답(break_start/end)에 임의 jitter를 준 지점
L1 / R1	correlation이 threshold(0.5) 아래로 처음 떨어지는/위로 처음 회복하는 지점
L2 / R2	correlation 곡선의 local minimum
L3 / R3	correlation이 가장 가파르게 하강/상승하는 지점

→ 하나(종료 후보)를 정확히 하나씩 골라라" — 숫자 좌표를 직접 쓰게 하지 않고 기호로만 선택하게 함:


▼ A안. correlation 그래프 있는 버전

C1 (진폭 점프)




- 설계: 중간 구간에서 Channel B 진폭만 2배로 튀는 신호. 후보는 correlation 곡선에서 자동 추출.
- 결과: 좌측 정확도 0%, 우측 0%. 30건 중 25건이 L2, 29건이 R2를 선택(correlation 최저점)

C3 (위상 반전)




- 설계: 중간 구간에서 Channel B가 A의 반대 부호가 되는 신호 (완전 역위상).

C2 (Flatline)



- 설계: 중간 구간에서 Channel B가 평평해지는 신호.
- 결과: 좌측 정확도 13.3%, 우측 0%.


C4 (지속적 위상 이탈, 참고용)



- 설계: 중간 구간부터 위상이 점진적으로 어긋나고 끝까지 회복 안 되는 신호(경계 케이스, 주 평가 제외).
- 결과: 좌측·우측 정확도 모두 0%, 오차도 제일 큼(좌측 63 step, 우측 67 step).

- 결과: 좌측 정확도 40% (5개 케이스 중 최고), 우측 6.7%.
Correlation이 -1.0까지 뚝 떨어지는 매우 뚜렷한 신호라,
correlation 기반 후보(L1/L2)
와 실제 정답이 상대적으로 가장 가까웠음.

C5 (미세 주파수 변화, 참고용)




- 설계: 중간 구간에서 Channel B 주파수만 살짝(5~10%) 빨라지는 신호(경계 케이스, 주 평가 제외).
- 결과: 좌측·우측 정확도 모두 0%. L2/R2(correlation 최저점)만 고르고 정답(L0/R0)과는 거리가 멀(좌측 19.5 step, 우측 31 step).

공통 패턴)

- 다섯 케이스 모두 모델은 원본 신호보다 ****correlation 곡선의 최저점·교차점(L1/L2, R1/R2)****을 우선 선택. 실제 생성 좌표에 가까운 정답(L0/R0)은 **150건 중 단 1건만** 선택.
- 즉, 모델 성능의 문제가 아니라 correlation 그래프와 정답 기준(L0/R0) 자체가 결과를 크게 좌우한 실험 설계의 영향으로 해석 가능.


▼ B안. correlation 그래프 없는 버전

C1 (진폭 점프)



- 결과: 좌측 정확도 0%, 우측 20%. 좌측 22건이 L1, 8건이 L2 — correlation 그래프를 뺐는데도 여전히 L0(정답)를 한 번도 안 고름.


C3 (위상 반전)



- 결과: 좌측 70% (5개 케이스 중 최고, 원본 대비 40% → 70% 큰 개선), 우측 0%.
- correlation 신호가 원래 제일 뚜렷했던 케이스라, correlation을 빼도 원본 파형에서 위상 반전 시작점을 잘 짚음 — 이 실험에서 가장 명확하게 개선된 유일한 케이스.


C5 (미세 주파수 변화, 참고용)

C2 (Flatline)




- 결과: 좌측 0%, 우측 23.3%. L1 15건, L2 14건, L0는 딱 1건.
- Sanity-5(원본, 좌측 13.3%)보다 오히려 소폭 하락.

C4 (지속적 위상 이탈, 참고용)



- 결과: 좌측 3.3%, 우측 0%. L1 22건, L2 7건.
- 여전히 거의 못 찾음, 오차도 제일 큼(좌측 31 step, 우측 67 step).



- 결과: 좌측 0%, 우측 30%. 좌측 29/30 건이 L2.
- 여전히 정답과 거리가 멀.

전체 요약)

지표	Sanity-5 (correlation 있음)	Sanity-5b (correlation 없음)
좌측 정확도	10.7%	14.7%
우측 정확도	1.3%	14.7%
좌우 동시 정답	0%	0%

핵심 발견)

- Correlation 그래프를 제거해도 5개 중 4개(C1/C2/C4/C5)는 거의 변화가 없고, C3만 40% → 70%로 개선.
- 모델은 여전히 ****이상이 시작되는 지점(L0)****보다 ****이상이 가장 두드러지는 지점(L1/L2)****을 선택하는 경향.
- 즉, 문제는 correlation 그래프보다 이상 시작점보다 가장 눈에 띄는 변화를 우선 보는 모델의 특성으로 보임.

▼ C안.prompt 만

이미지는 아무것도 표시 안된 이미지 & prompt 에 후보 넣기

[prompt]

...

관계가 시작되는 지점의 후보 시간값: $L0=96$, $L1=126$, $L2=120$, $L3=114$.

관계가 끝나는(회복되는) 지점의 후보 시간값: $R0=196$, $R1=150$, $R2=175$, $R3=181...$

C1 (진폭 점프)

- **결과:** 좌측 **0%**, 우측 **10%**. L1 82건대 물림(전체 기준) — 여전히 정답(L0) 거의 안 고름.

C2 (Flatline)

- **결과:** 좌측 **10%**, 우측 **36.7%** (5c에서 가장 개선된 지표 중 하나).

C3 (위상 반전)

- **결과:** 좌측 **36.7%**, 우측 **30%**, **좌우 동시 정답 3.3%** (150건 중 유일하게 "동시 정답"이 나온 케이스군).
- 세 버전(5/5b/5c) 통틀어 C3가 항상 가장 나은 케이스라는 패턴이 재확인 됨.

C4 (지속적 위상 이탈, 참고용)

- **결과:** 좌측·우측 모두 **0%**. 오차도 제일 큼(좌측 59.6 step, 우측 48.7 step) — 세 버전 중 최악.
- **결과:** 좌측 **0%**, 우측 **6.7%**.

▼ A,B,C안 전체 결과 분석

지표	5 (correlation)	5b (correlation 없음)	5c (텍스트 후보)
좌측 정확도	10.7%	14.7%	9.3%
우측 정확도	1.3%	14.7%	16.7%
좌우 동시 정답	0%	0%	1.3%
L0 선택 횟수(전체 150건 중)	1	2	5

좌측(L) 선택 분포

후보	A (correlation)
L0 (정답)	1
L1	48
L2	102
L3	0

우측(R) 선택 분포

후보	A (correlation)
R0 (정답)	1
R1	22
R2	127
R3	0

핵심 발견)

- 모델은 데이터 생성 시점(L0/R0)보다 ****변화가 가장 두드러지는 지점(L1/L2, R2/R3)****을 이상 시작점으로 선택.
- 이 패턴은 correlation 제공 여부(A/B)나 텍스트 후보(C)와 관계없이 동일하게 나타남.
- 즉, 모델은 ****"정확한 시작점"보다 "가장 크게 깨져 보이는 지점"****을 이상 발생 시점으로 해석하는 경향.
- 이는 사람도 노이즈가 있는 신호에서 미세한 시작점보다 가장 눈에 띄는 변화 지점을 직관적으로 선택하는 것과 유사한 특성으로 볼 수 있음.

▼ Sanity6-multi channel 실험
multi-channel 붕괴 실험)

정상 쌍: 무조건 C0(완전 동기화, 노이즈만 다른 기본 케이스)

붕괴 쌍: C1(진폭점프), C2(flatline), C3(위상반전) 중 하나를 매번 랜덤으로 뽑아서 사용

시나리오	총 채널	총 쌍 개수
N2_none	2	1
N2_single	2	1
N4_none	4	2
N4_single	4	2
N4_multi	4	2
N8_none	8	4
N8_single	8	4
N8_multi	8	4

각 시나리오 결과)

시나리오	Accuracy
N2_none	1.000
N2_single	0.800
N4_none	1.000
N4_single	0.933
N4_multi	0.567
N8_none	1.000
N8_single	0.867
N8_multi	0.850

핵심 발견)

1. 오귀속(Misattribution) — 이상은 찾았지만 잘못된 채널에 귀속

- 놓친 사례의 약 15%는 이상 자체는 정확히 감지했지만 다른 채널쌍으로 잘못 판단.
- 즉, “이상이 있다”는 감지는 성공했지만 “어느 채널이 이상인지”를 혼동하는 경우.

2. 오탐(False Positive)은 매우 적음

- 채널 수가 2개에서 8개로 늘어나도 오탐은 0% → 약 3% 수준.
- 즉, 채널이 많아져도 확실할 때만 broken을 판단하는 보수적인 성향은 유지.

3. 붕괴 유형별 난이도 변화

- 2채널(Sanity-1)에서는 Flatline가 가장 쉽고, 위상반전이 가장 어려움.

- 8채널에서는 반대로 Flatline 성능이 가장 크게 감소(68%), 위상반전은 오히려 개선(62%).
- 즉, 채널 수가 증가하면서 이상 유형별 난이도가 달라짐.

4. 채널 순서 효과(Order Effect)

- 앞쪽(1·2번째) 채널쌍은 거의 모두 정확하게 판단.
- 뒤쪽(3·4번째) 채널쌍은 정답률이 약 **42~46%**까지 감소.
- 즉, 여러 채널을 한 번에 판단하면 뒤쪽 항목의 성능이 크게 떨어지는 순서 효과가 나타남.

순서	채널	정답률
1번째	P1	100%
2번째	P2	100%
3번째	P3	42%
4번째	P4	46%

▼ Sanity7-sanity1추가 실험

prompt 2개로 실험해봄

[prompt1]<- sanity1과 동일
두 시계열 채널 "Channel A"와 "Channel B"가 같은 시간축 위에 그려진 플롯을 보여줍니다.

과제: Channel A와 Channel B의 관계가 플롯된 구간 전체에서 *유지(MAINTAINED)**되는지, 아니면 어느 시점에서 **붕괴(BREAKS DOWN)**되어 (완전히는) 회복되지 않는지 판단하라.

"관계"란 두 채널이 함께 움직이는 방식(동기화, 안정적인 비례·위상 관계)을 뜻하며, 신호 자체의 절대값을 의미하지 않는다.

"maintained" 또는 "broken" 중 정확히 하나로 답하라.

[prompt2]

두 시계열 채널 "Channel A"와 "Channel B"가 같은 시간축 위에 그려진 플롯을 보여줍니다.

과제: 이 플롯에 이상 구간(anomalous interval)이 있는지, 아니면 두 채널이 전체 구간 내내 정상적으로 행동하는지 판단하라.


"maintained" 또는 "broken" 중 정확히 하나로 답하라.

아래 JSON 형식으로만 답하라: {"answer": "maintained"|"broken", "reason": "<1-3문장>", "confidence": <0.00-1.00>}


케이스	이전(관계 정의 있음)	새 프롬프트(구간 프레이밍)
H1a (다른 주파수)	70.0%	93.3% ↑
H1b (다른 스케일)	63.3%	100% ↑↑ (완전 해결)
H1c (항상 반위상)	100%	100%
H1d (고정 위상차)	93.3%	100% ↑
H2 (분산만 변화)	53.3%	46.7% ↓ (여전히 최악)
H3 (trend 발산)	100%	96.7% ↓ (약간 하락)

케이스	이전(관계 정의 있음)	새 프롬프트(구간 프레이밍)
H4 (주기성 붕괴)	80.0%	70.0% ↓ (더 나빠짐)
전체	80.0%	86.7% ↑


H1a




H1b




H1c




H1d



H2



H3



H4

